04-03
Méthodes simples de prévisions

NOUS ÉCLAIRONS.
VOUS BRILLEZ.

FORMATION CONTINUE
ET SERVICES AUX ENTREPRISES

Cégep de Sainte-Foy

Spécialisation technique en intelligence artificielle
Algorithmes d’apprentissage non supervisé — 420-A58-SF — M. Swawola, M.Sc.

Sommaire

1 Prévision simples

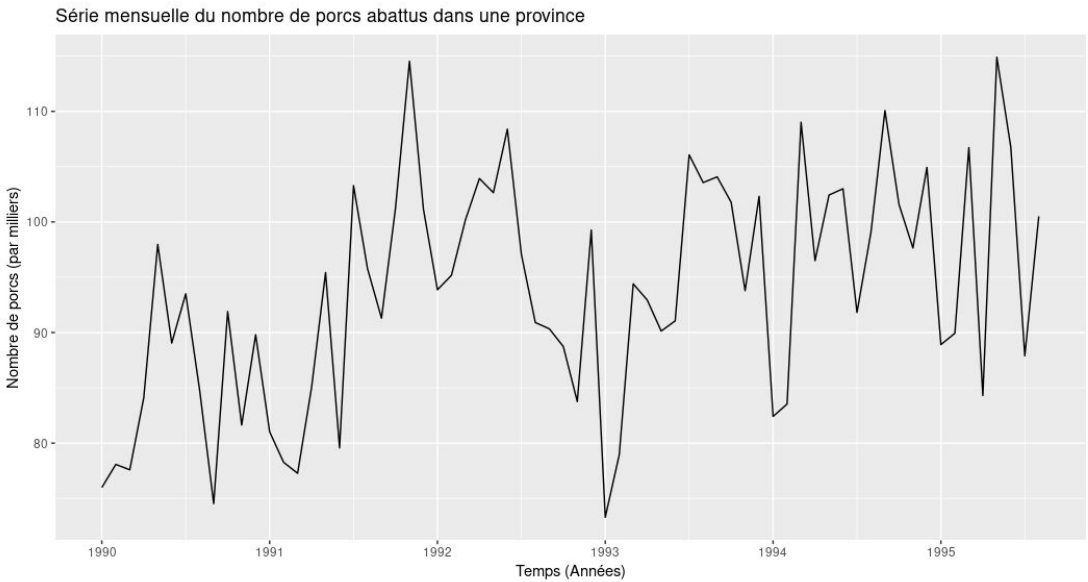

Comment feriez-vous des prévisions à partir de cette série temporelle ?

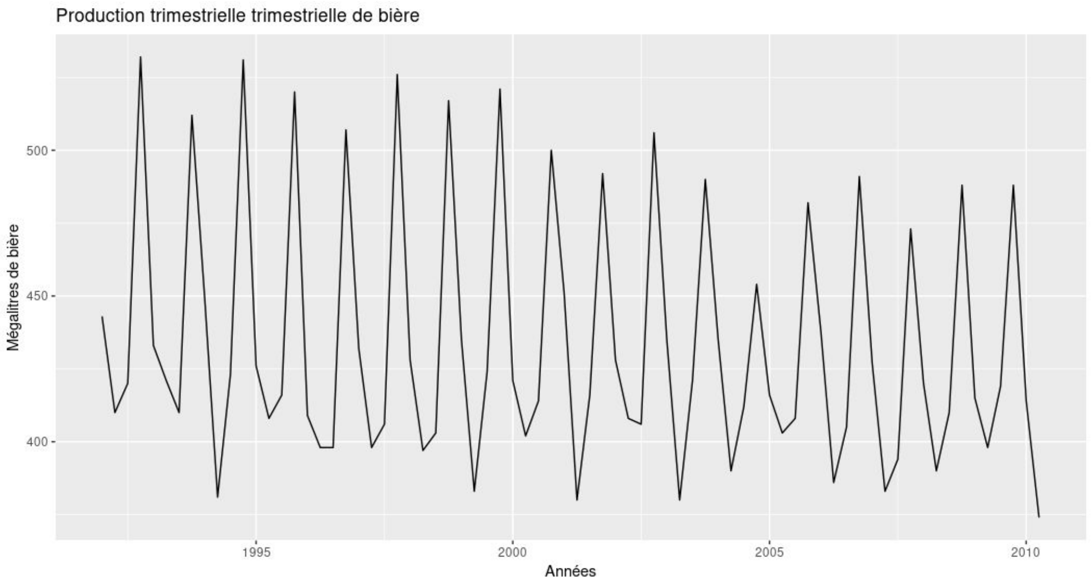

Comment feriez-vous des prévisions à partir de cette série temporelle ?

Méthode de la moyenne

- Toutes les prévisions des valeurs futures sont égales à la moyenne des données historiques

$$\hat{x}_{T+h|T} = \frac{1}{T}(x_1 + \cdots + x_T)$$

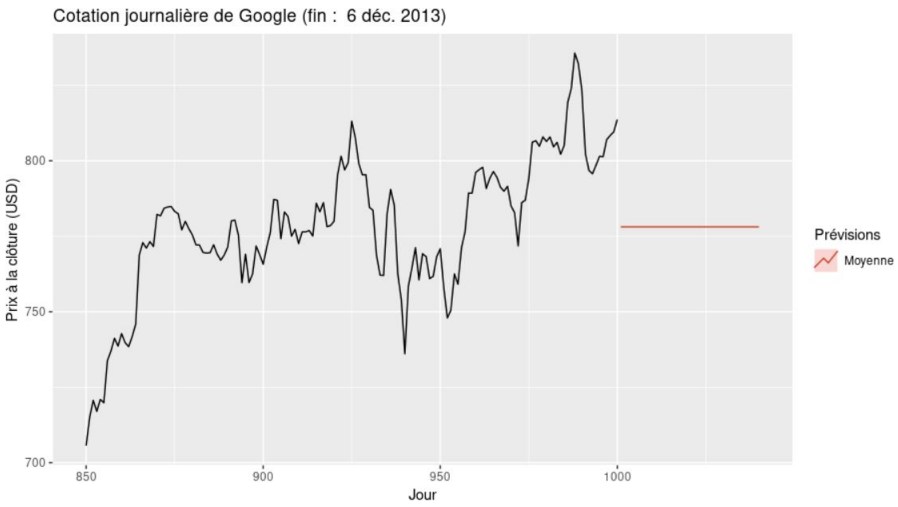

Méthode naïve

- Toutes les prévisions sont égales à la dernière observation

$$\hat{x}_{T+h|T} = x_T$$

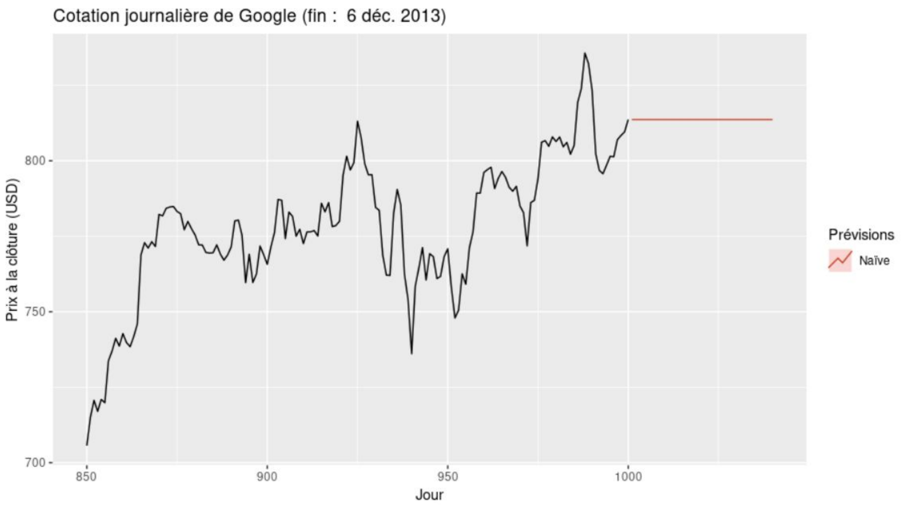

Méthode de la dérive

- Les prévisions sont calculées via par formule

$$\hat{x}_{T+h|T} = x_T + \frac{h}{h-1}(x_T - x_1)$$

- Équivaut à extrapoler une ligne droite entre la première et la dernière observation

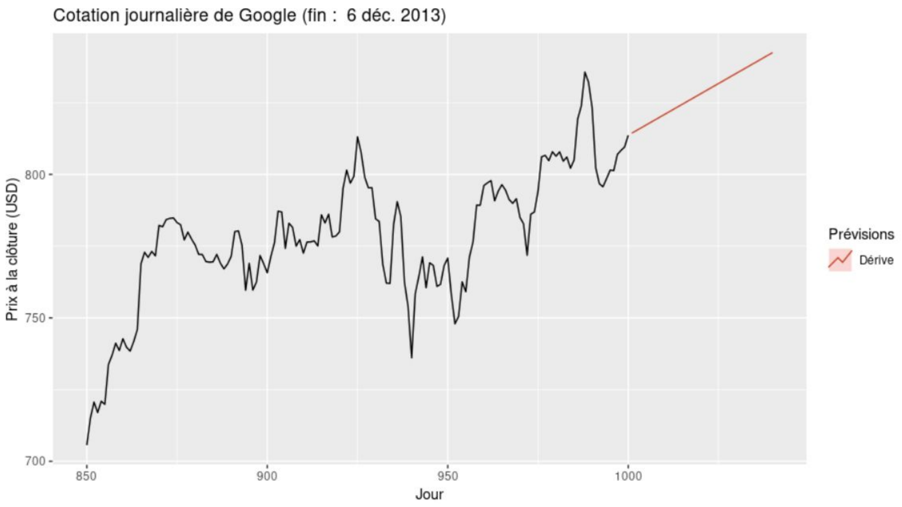

Méthode naïve saisonnière

- Toutes les prévisions sont égales à la dernière valeur de la précédente saison

  $$\hat{x}_{T+h|T} = x_{T+h-m(k+1)}$$

  où **m** est la longueur de la saison et **k** est la partie entière de **(h - 1) / m**

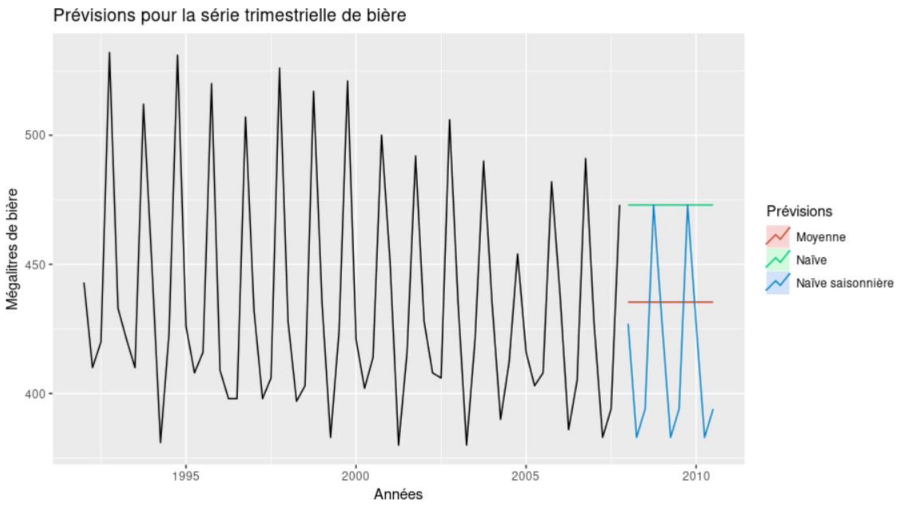

Fonctions de prévision R

- **Moyenne**

```
meanf(x, h=12)
```

- **Naïve**

```
naive(x, h=12)
```

- **Naïve saisonnière**

```
snaive(x, h=24)
```

- **Dérive**

```
rwf(x, drift=TRUE, h=20)
```

Valeurs ajustées

- $\hat{x}_{t|t-1}$ est la prévision de x_t basée sur $x_1, \dots , x_{t-1}$. On les appelle **valeurs ajustées**.
- On notera $\hat{x}_t = \hat{x}_{t|t-1}$
- Par exemple

  $\hat{x}_t = \bar{x}$ par la méthode de la moyenne

  $\hat{x}_t = x_{t-1} + (x_t - x_1)/(T-1)$ par la méthode de la dérive

Résidus

- Un **résidu** à la date ***t*** est la différence entre la valeur observée et la valeur ajustée. Le résidu est noté ϵ_t

$$\epsilon_t = x_t - \hat{x}_{t|t-1}$$

- **Hypothèses**

  Les ϵ_t sont de moyenne nulle

  Les ϵ_t sont deux à deux non corrélés

- **Propriétés utiles**

  Les ϵ_t ont une variance constante

  Les ϵ_t suivent une loi normale

Exemple - Série Google

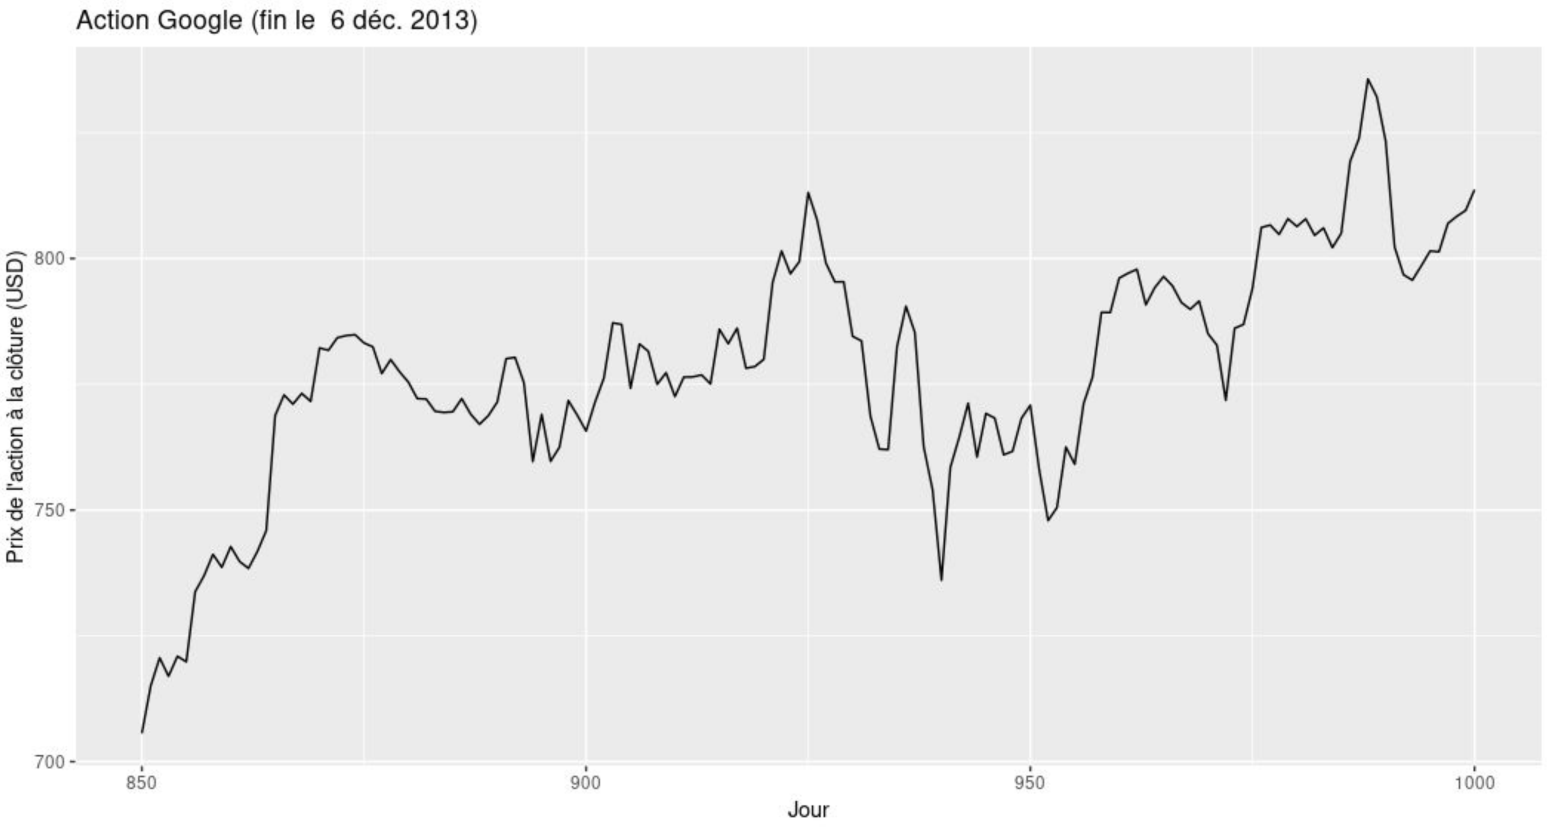

Exemple - Série Google

- La prévision naïve est

$$x_t - \hat{x}_{t|t-1} = x_{t-1}$$

- Le résidu associé est donc

$$\epsilon_t = x_t - x_{t-1}$$

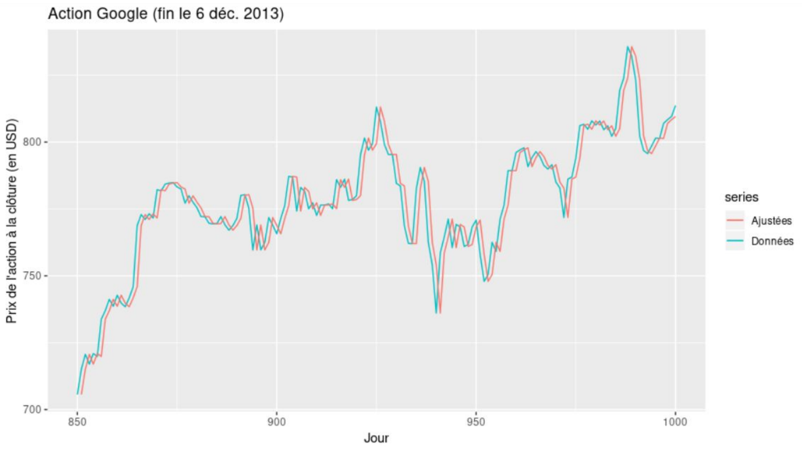

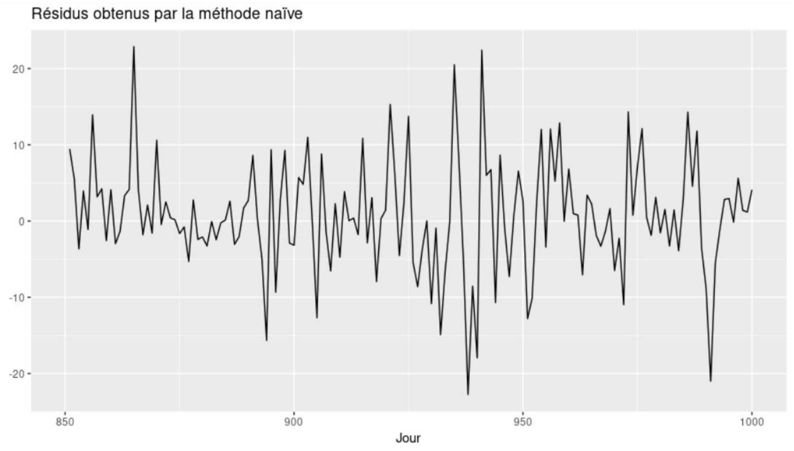

Exemple - Série Google

- Code R

```r
# Série goog150 et valeurs ajustées
fits <- fitted(naive(goog150))
autoplot(goog150, series="Données") +
  autolayer(fits, series="Ajustées") +
  xlab("Jour") + ylab("Prix de l'action à la clôture (en USD)") +
  ggtitle("Action Google (fin le 6 déc. 2013)")

# Série goog150 et résidus
res <- residuals(naive(goog150))
autoplot(res) + xlab("Jour") + ylab("") +
  ggtitle("Résidus obtenus par la méthode naïve")
```

Exemple - Série Google - Étude des résidus

- L'étude des résidus est facilitée par le fonction `checkresiduals`

```
checkresiduals(naive(goog150))
```

Exemple - Série Google - Étude des résidus

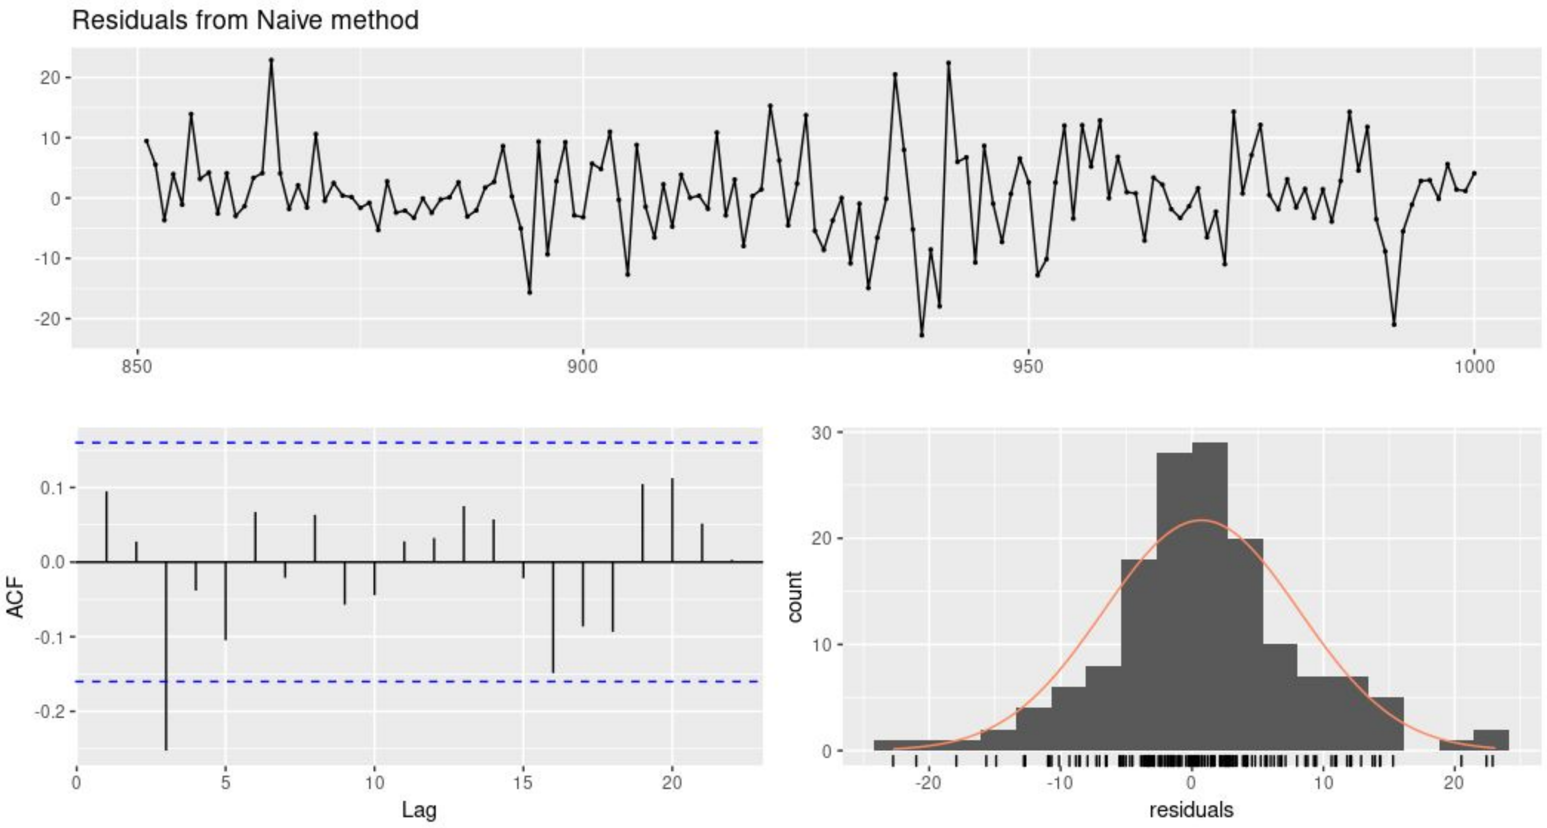

Exemple - Série Google - Étude des résidus

- ```
  Ljung-Box test

  data:  Residuals from Naive method

  Q* = 15.623, df = 10, p-value = 0.111
  ```

- On ne rejette pas l'hypothèse que les résidus sont issus d'un bruit blanc
  ```

Étude des résidus

- Une **bonne méthode de prévision** produira des résidus ayant les propriétés suivantes:
    - Les résidus ne sont pas corrélés. S’il existe des corrélations entre les résidus, il reste des informations dans les résidus qui devraient être utilisées dans le calcul des prévisions.
    - Les résidus ont une moyenne nulle. Si les résidus ont une moyenne autre que zéro, les prévisions sont biaisées.
- Toute méthode de prévision qui ne satisfait pas à ces propriétés peut être améliorée.

2

Mesures de précision des prévisions

Mesures de précision des prévisions

- Soient $\mathbf{x_t}$ une observation et $\mathbf{f_t}$ sa prévision. Pour tout $\mathbf{t = 1, ..., T}$

$$\mathrm{MAE} = \frac{1}{T}\sum_{t=1}^{T}|x_t - f_t|$$

Mean absolute error

$$\mathrm{MSE} = \frac{1}{T}\sum_{t=1}^{T}(x_t - f_t)^2$$

Mean squared error

$$\mathrm{MAPE} = \frac{1}{100T}\sum_{t=1}^{T}\frac{(|x_t - f_t|)}{|x_t|}$$

Mean absolute percentage error

- Toutes sauf le **MAPE** dépendent de l'échelle des observations

Mesures de précision des prévisions

- Une autre mesure est le MASE

$$\mathrm{MASE} = \frac{1}{T}\sum_{t=1}^{T}\frac{|x_t - f_t|}{q}$$

Mean absolute scale error

- Où **q** est une mesure stable de l'échelle de la série (X_t)

Mesures de précision des prévisions

- Exemple pour une **série non saisonnière**

$$q = \frac{1}{T-1} \sum_{t=2}^{T} |x_t - x_{t-1}|$$

- On remarque que les **MASE** équivaut au **MAE** pour la méthode naïve

Mesures de précision des prévisions

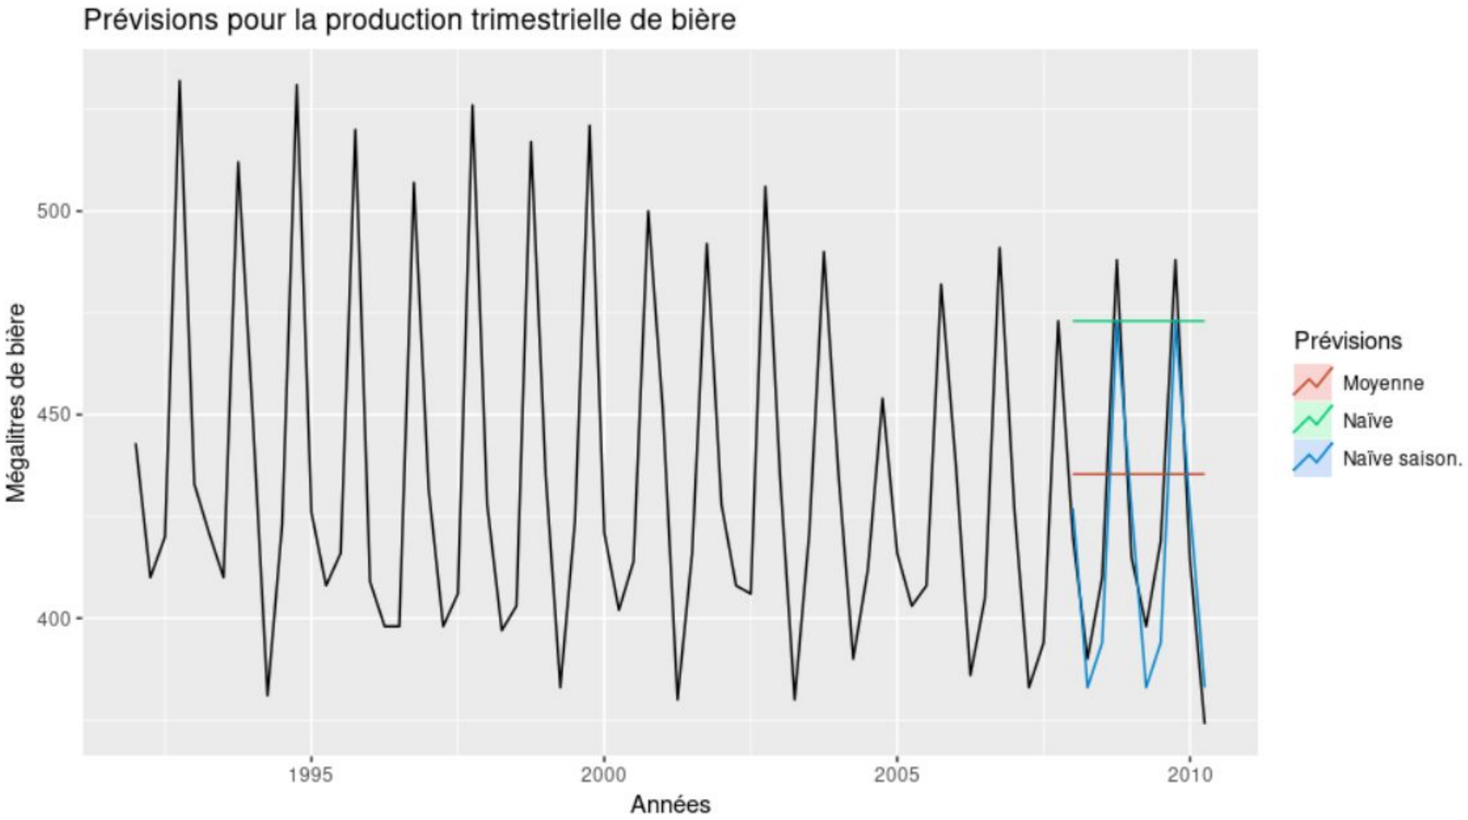

Mesures de précision des prévisions

- Code R

```r
# Série bière et mesures de précision
biere <- window(ausbeer, start=1992, end=c(2007,4))
bierefit1 <- meanf(biere, h=10)
bierefit2 <- rwf(biere, h=10)
bierefit3 <- snaive(biere, h=10)
autoplot(window(biere, start=1992)) +
      autolayer(bierefit1, series="Moyenne", PI=FALSE) +
      autolayer(bierefit2, series="Naïve", PI=FALSE) +
      autolayer(bierefit3, series="Naïve saison.", PI=FALSE) +
      xlab("Années") + ylab("Mégalitres de bière") +
      ggtitle("Prévisions pour la production trimestrielle de bière") +
      guides(colour=guide_legend(title="Prévisions"))
```

Mesures de précision des prévisions

- Code R

```
biere3 <- window(biere, start=2008)
accuracy(bierefit1, biere3)
accuracy(bierefit2, biere3)
accuracy(bierefit3, biere3)
```

	MAE	MAPE	RMSE	MASE
Moyenne	34.83	8.28	38.45	2.44
Naïve	57.40	14.18	62.69	4.01
Naïve Saison.	13.40	3.17	14.31	0.94

Intervalles de précision

- Un intervalle de confiance est un intervalle dans lequel on espère que se situe x_{T+h} avec une certaine probabilité
- Si on suppose les **erreurs gaussiennes**, alors l'intervalle de prévision à 95 % sera de la forme

$$\hat{x}_{T+h} \pm 1.96 \times \hat{\sigma}_h$$

où $\hat{\sigma}_h$ est l'écart-type associé à la loi pour **h** décalages

- Quand **h = 1**, $\hat{\sigma}_1$ peut être estimé via les résidus

Mesures de précision des prévisions

- Prévisions naïves avec un intervalle de prévision:

```r
res_sd <- sqrt(mean(res^2, na.rm=TRUE))
naive(goog150, level=95)
```

```
     Point Forecast    Lo 95    Hi 95
1001         813.67 799.0449 828.2951
1002         813.67 792.9869 834.3530
1003         813.67 788.3385 839.0015
1004         813.67 784.4197 842.9202
1005         813.67 780.9672 846.3728
1006         813.67 777.8459 849.4941
1007         813.67 774.9755 852.3644
1008         813.67 772.3039 855.0361
1009         813.67 769.7946 857.5454
1010         813.67 767.4213 859.9187
```

Mesures de précision des prévisions

- Remarques
    - Il est très important d'avoir des intervalles de précision, ce qui donne une information très pertinente sur l'efficacité des dites prévisions
    - Les intervalles de confiance requièrent que le modèle sous-jacent soit stochastique
    - Le calcul des prévisions à l'horizon **h** nécessitent une approche plus sophistiquée, avec des intervalles de confiance qui grossissent avec l'horizon **h** de prévision

Mesures de précision des prévisions

- Si les résidus sont gaussiens, non corrélés deux à deux, et d'écart-type $\hat{\sigma}$, alors on a
  - Méthode de la moyenne : $\hat{\sigma}_h = \hat{\sigma}\sqrt{1 + 1/T}$
  - Méthode naïve : $\hat{\sigma}_h = \hat{\sigma}\sqrt{h}$
  - Méthode naïve saison. : $\hat{\sigma}_h = \hat{\sigma}\sqrt{h}$
  - Méthode de la dérive : $\hat{\sigma}_h = \hat{\sigma}\sqrt{h(1 + h/T)}$

  où **k** est la partie entière de **(h - 1)/m**

Mesures de précision des prévisions

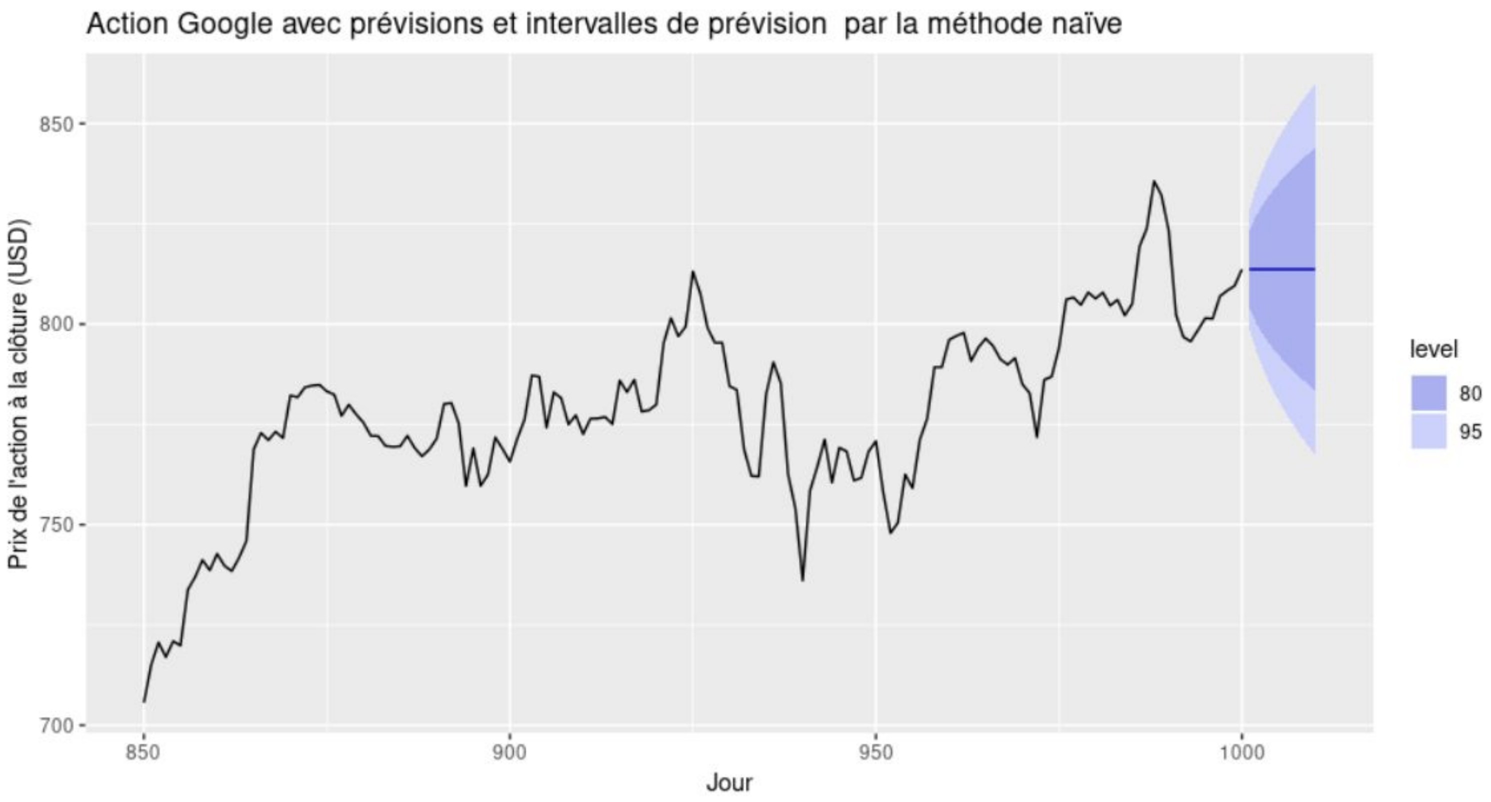

Pull de https://github.com/mswawola-cegep/420-a58-sf.git

04-04-TP

3

Références

Références

[1] Cours “R et la prévision de séries temporelles” de Michel Carbon - Université Laval