04-07 Le modèle ARIMA - SARIMA

NOUS ÉCLAIRONS. VOUS BRILLEZ.

FORMATION CONTINUE ET SERVICES AUX ENTREPRISES



Sommaire

- Modèle et notations
- 2. La commande **auto.arima** par l'exemple
- 3. Digression: valeurs manquantes et aberrantes
- 4. Références

Modèle et notations

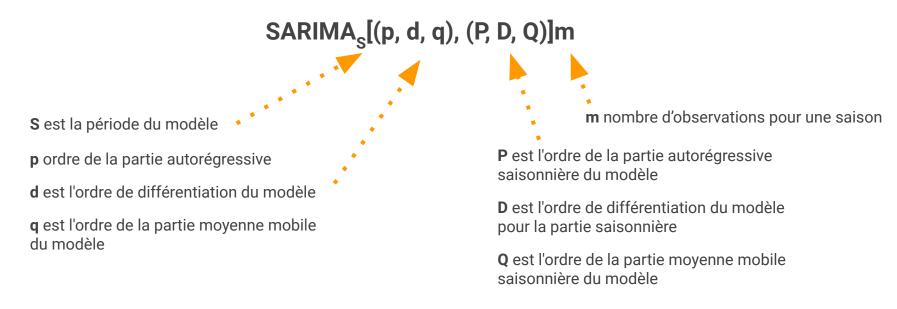
Le modèle ARIMA - SARIMA

- ARIMA (Autoregressive Integrated Moving Average) est l'une des méthodes de prévision les plus utilisées pour les séries univariées
- Cette méthode possède cependant une faiblesse majeure: elle ne supporte pas les séries présentant une composante saisonnière 🙁 🙁
- SARIMA (S pour Seasonal) est une extension d'ARIMA prenant en compte la composante saisonnière d'une série univariée
- Le modèle SARIMA complet est donné par

$$\Phi_{\mathsf{p}}(\mathsf{B})\Phi_{\mathsf{P}}(\mathsf{B}^{\mathsf{S}})
abla^{\mathsf{d}}
abla^{\mathsf{D}}_{\mathsf{S}}\mathsf{X}_{\mathsf{t}} = \Theta_{q}(B)\Theta_{Q}(B^{S})\epsilon_{t}$$

SARIMA

Un processus satisfaisant le modèle précédent est appelé processus



Notations (optionnel)

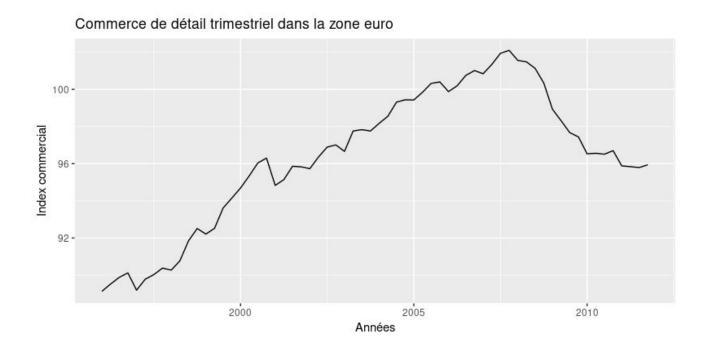
$$\Phi_{\mathsf{p}}(\mathsf{B})\Phi_{\mathsf{P}}(\mathsf{B}^{\mathsf{S}})
abla^{\mathsf{d}}
abla^{\mathsf{D}}_{\mathsf{S}}\mathsf{X}_{\mathsf{t}} = \Theta_{q}(B)\Theta_{Q}(B^{S})\epsilon_{t}$$

- S période du modèle (ou saisonnalité) Exemple: S = 4 pour séries trimestrielles, etc...
- Φ_p , Φ_q , Θ_q , Θ_Q sont des polynômes de degrés respectifs **p**, **P**, **q**, **Q** dont les racines sont de module strictement supérieurs à 1
- $(\epsilon_t)_{t \in \mathbb{Z}}$ est un bruit blanc



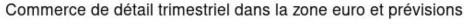
Question 1

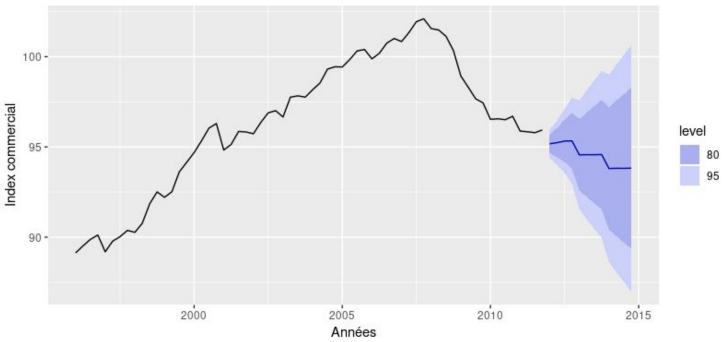
Que pouvez vous dire de la série suivante ?



Code R

```
euretail %>%
   auto.arima() %>%
   forecast(h=12) %>%
   autoplot() +
      ylab("Index commercial") +
      xlab("Années") +
      ggtitle("Commerce de détail trimestriel dans la zone euro et prévisions")
```



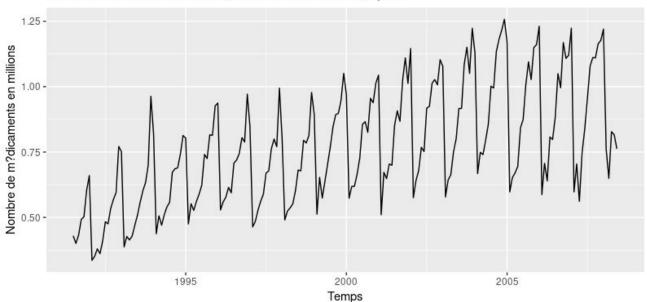


```
Series: .
ARIMA(0,1,3)(0,1,1)[4]
Coefficients:
               ma2 ma3
        ma1
                              sma1
     0.2630 0.3694 0.4200 -0.6636
s.e. 0.1237 0.1255 0.1294 0.1545
sigma^2 estimated as 0.156: log likelihood=-28.63
ATC=67.26 ATCc=68.39 BTC=77.65
```

Question 2

Que pouvez vous dire de la série suivante ?

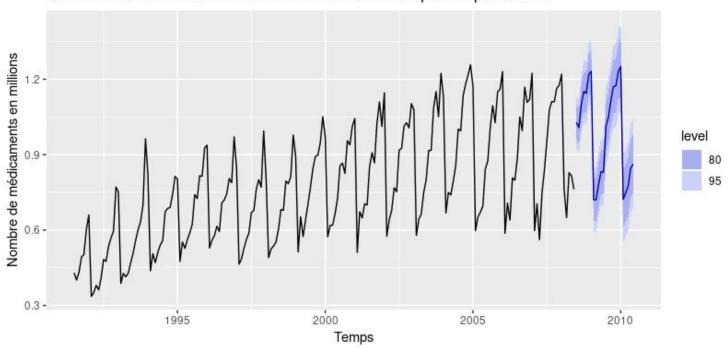




Code R

```
h02 %>%
    auto.arima() %>%
    forecast(h=24) %>%
    autoplot() +
        ggtitle("Nombre mensuel total de médicaments antidiabétiques et prévisions") +
        xlab("Temps") +
        ylab("Nombre de médicaments en millions")
```





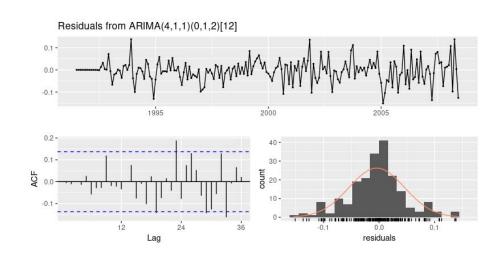
```
Series: .
ARIMA (4,1,1) (0,1,2) [12]
Coefficients:
            ar2 ar3 ar4 ma1 sma1
        ar1
                                                     sma2
     0.0888 0.3386 0.2302 -0.2233 -0.9068 -0.4798 -0.1624
s.e. 0.1063 0.0976 0.0894 0.0850 0.0853 0.0913
                                                  0.0930
sigma^2 estimated as 0.00276: log likelihood=291.7
ATC=-567.4 ATCc=-566.6 BTC=-541.38
```

On analyse les résidus

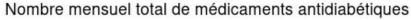
```
fit.arima <- auto.arima(h02)
checkresiduals(fit.arima)</pre>
```

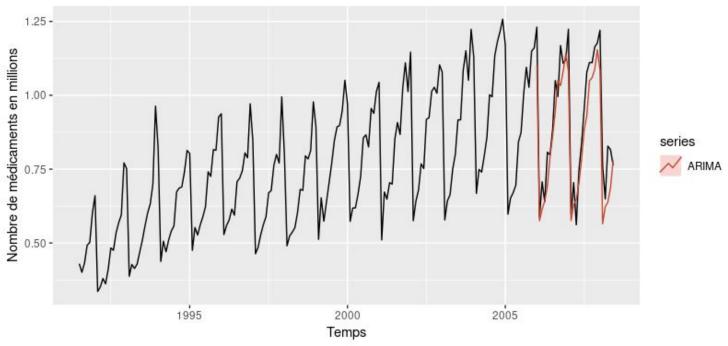
Ljung-Box test

```
data: Residuals from ARIMA(4,1,1)(0,1,2)[12]
Q^* = 26.081, df = 17, p-value = 0.07299
Model df: 7. Total lags used: 24
```



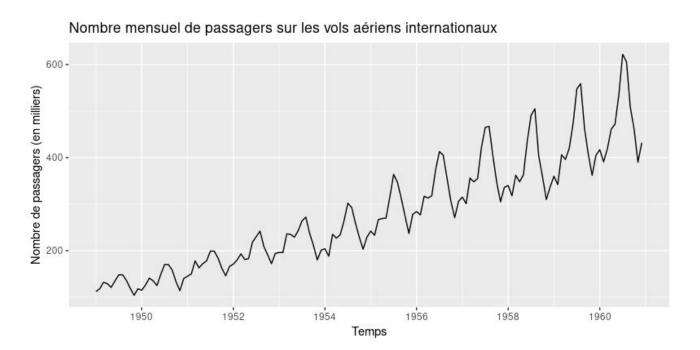
 On peut faire un test d'évaluation de la pertinence des prévisions. On va retrancher ici 2 ans





Question 3

Que pouvez vous dire de la série suivante ?

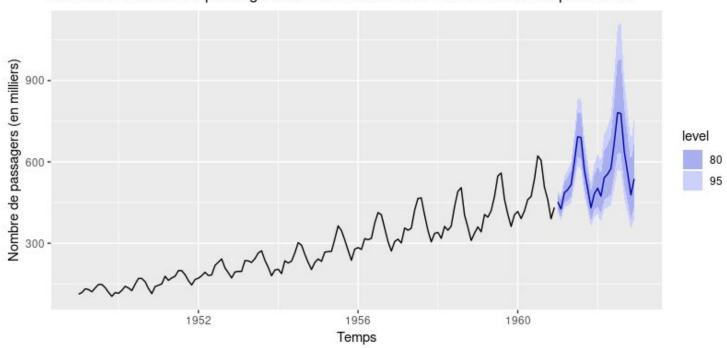


Code R

```
airline %>%
    auto.arima(lambda="auto") %>%
    forecast(h=24) %>%
    autoplot() +
        ggtitle("Nombre mensuel de passagers sur les vols aériens internationaux") +
        xlab("Temps") +
        ylab("Nombre de passagers (en milliers)")
```

```
Series: airline
ARIMA(0,1,1)(0,1,1)[12]
Box Cox transformation: lambda = -0.2947156
Coefficients:
         ma1
                 sma1
     -0.4355 -0.5847
s.e. 0.0908 0.0725
sigma^2 estimated as 5.855e-05: log likelihood=451.6
AIC=-897.19 AICc=-897.01 BIC=-888.57
```

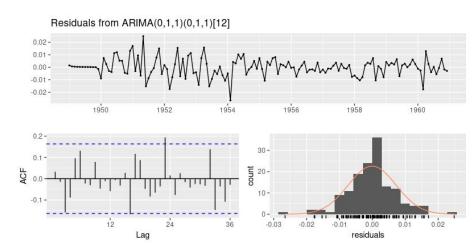




On analyse les résidus

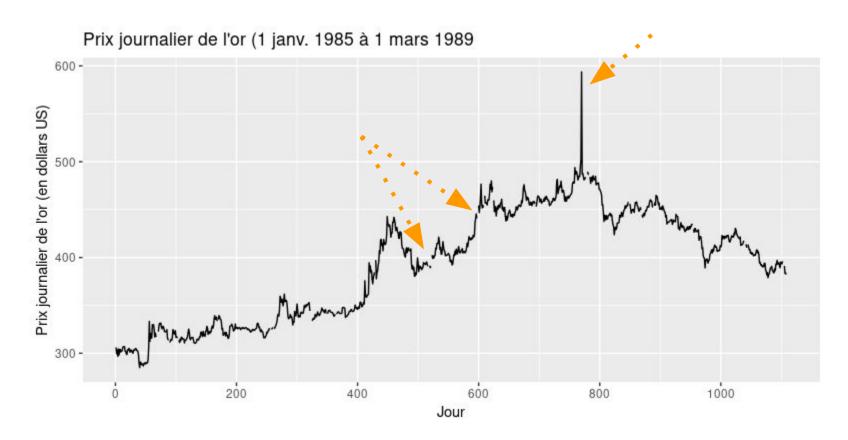
```
Fit1.arima <- auto.arima(airline, lambda="auto")
summary(fit1.arima)
checkresiduals(fit1.arima)</pre>
```

Ljung-Box test data: Residuals from ARIMA(0,1,1)(0,1,1)[12] $Q^* = 28.635, df = 22, p-value = 0.1556$ Model df: 2. Total lags used: 24





Valeurs manquantes et aberrantes

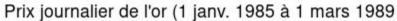


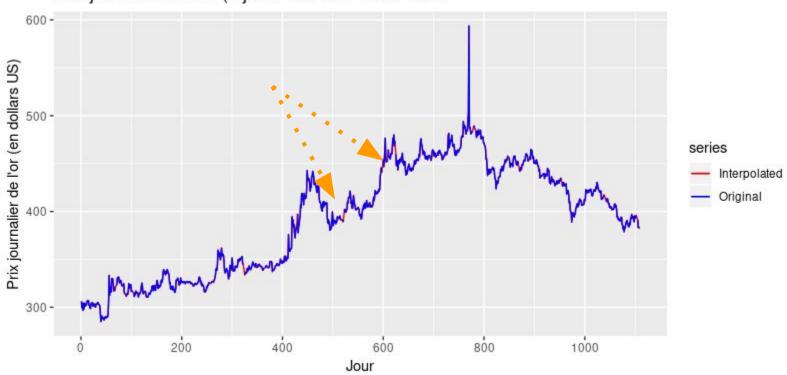
La commande na . interp

- Interpolation automatique des valeur manquantes (voir cours de préparation des données)
- Code R

```
gold1 <- na.interp(gold)</pre>
```

La commande na . interp



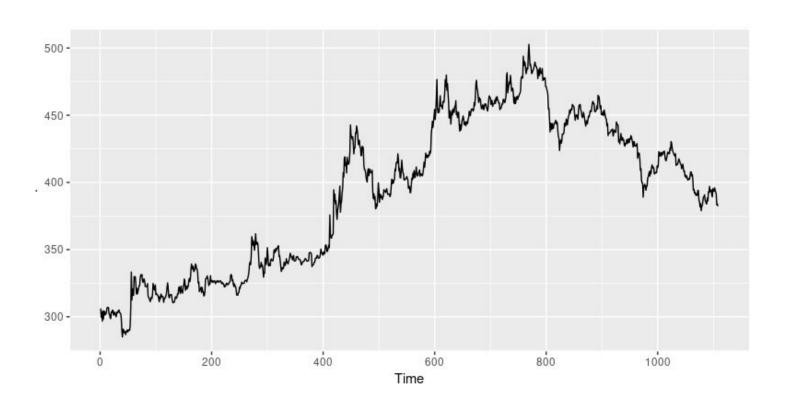


La commande tsclean

- Supprime automatiquement les valeurs aberrantes (voir cours de préparation des données)
- Code R

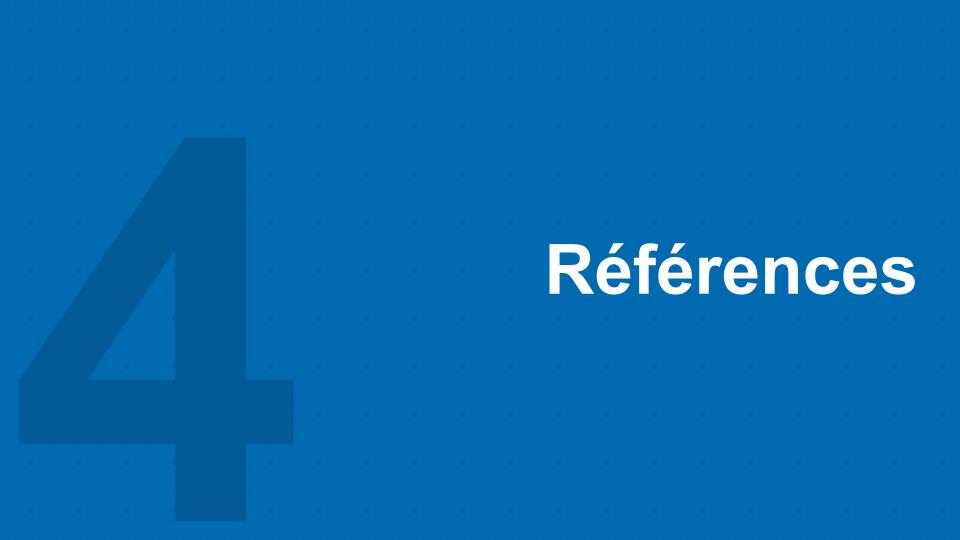
```
gold %>% tsclean()
```

La commande tsclean





Pull de https://github.com/mswawola-cegep/420-a58-sf.git
04-07-TP



Références

- [1] Cours "R et la prévision de séries temporelles" de Michel Carbon Université Laval
- [2] A Gentle Introduction to SARIMA for Time Series Forecasting in Python
- [3] MODÈLE DE TYPE ARIMA
- [4] Analysez et modélisez des séries temporelles Entraînez des modèles SARIMA